Actividad práctica: árboles de decisión y máquinas de soporte vectorial

Asignatura: Aprendizaje de Máquina Supervisado
Docente: Luis Alberto Jaimes C.
Modalidad: Trabajo por grupos

1. Propósito de la actividad

Cada grupo resolverá un problema de clasificación diferente a partir de un dataset sintético construido para esta actividad. El objetivo no consiste únicamente en obtener una predicción, sino en relacionar el comportamiento del modelo con los fundamentos matemáticos estudiados.

La actividad integra los contenidos desarrollados en las sesiones de árboles de decisión y máquinas de soporte vectorial:

- particiones binarias recursivas;
- índice de Gini, entropía y ganancia de información;
- profundidad, número de hojas y complejidad del árbol;
- pre-poda mediante `max_depth`, `min_samples_split` y `min_samples_leaf`;
- control explícito del número de hojas mediante `max_leaf_nodes`;
- poda por complejidad de coste mediante `ccp_alpha`;
- hiperplano separador, función de decisión y margen;
- vectores de soporte;
- kernels lineal, polinomial y RBF;
- efecto de C, γ y del grado d del kernel polinomial.

2. Asignación de datasets

Cada grupo trabajará exclusivamente con el archivo asignado en la siguiente tabla. La última columna indica el número de características predictoras p; el identificador de cada registro no se utiliza como predictor.

Grupo	Contexto	Archivo	p
1	Control de calidad de piezas mecanizadas	`grupo01_calidad_piezas.csv`	2
2	Mantenimiento predictivo de rodamientos	`grupo02_falla_rodamiento.csv`	2
3	Retención de clientes de una plataforma SaaS	`grupo03_churn_saas.csv`	4
4	Riesgo de incumplimiento de crédito para pymes	`grupo04_riesgo_credito_pyme.csv`	5
5	Riesgo de enfermedad foliar en cultivo	`grupo05_enfermedad_cultivo.csv`	3
6	Retrasos en entregas urbanas y regionales	`grupo06_retraso_logistico.csv`	4
7	Flujos anómalos en una red corporativa	`grupo07_anomalia_red.csv`	2
8	Conversión de prospectos comerciales	`grupo08_conversion_comercial.csv`	3
9	Eventos críticos en equipos eléctricos	`grupo09_evento_energia.csv`	6
10	Lotes fuera de especificación en un proceso industrial	`grupo10_proceso_quimico.csv`	3

Variable objetivo y cálculo manual inicial

Para el cálculo manual de impureza cada grupo utilizará la variable y los dos umbrales indicados a continuación. Los umbrales se eligieron dentro del rango observado del dataset y permiten comparar dos particiones candidatas.

Grupo	Variable objetivo	Variable para partición manual	s_1	s_2
1	`rechazo`	`rugosidad_ra`	1.600	2.039
2	`falla_rodamiento`	`temperatura_c`	69.31	75.32
3	`abandona`	`uso_mensual_horas`	14.63	21.88
4	`incumplimiento`	`endeudamiento_pct`	45.91	58.77
5	`enfermedad_foliar`	`humedad_relativa_pct`	66.89	77.50
6	`retraso`	`indice_trafico`	4.622	6.239
7	`anomalia`	`paquetes_por_segundo`	640.0	1030.0
8	`convierte`	`minutos_sitio`	6.78	10.70
9	`evento_critico`	`temperatura_c`	54.41	62.31
10	`producto_fuera_especificacion`	`presion_bar`	48.99	55.49

3. Condiciones comunes de trabajo

Para que las comparaciones sean reproducibles, todos los grupos deben utilizar las siguientes condiciones:

1. eliminar de **X** la columna identificadora del registro;
2. utilizar todas las demás características predictoras del dataset;
3. usar la variable objetivo indicada en la tabla anterior;
4. separar entrenamiento y prueba con 75 % y 25 %, respectivamente;
5. emplear `random_state=42` y `stratify=y`;
6. conservar exactamente la misma partición entrenamiento/prueba para los árboles y las SVM;
7. estandarizar las características para SVM utilizando únicamente el conjunto de entrenamiento;
8. no estandarizar las características para el árbol de decisión;
9. reportar como mínimo la exactitud de entrenamiento y de prueba;
10. no utilizar `GridSearchCV`, `RandomizedSearchCV` ni procedimientos automáticos de búsqueda de hiperparámetros. Los parámetros deben estudiarse mediante experimentos controlados, modificando explícitamente los valores solicitados.

Un esquema inicial es:

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.25,
    random_state=42,
    stratify=y
)
```

Parte I: crecimiento, control de complejidad y poda del árbol

4. Árbol sin restricciones

Ajustar dos árboles iniciales:

- uno con `criterion="gini"`;

- otro con `criterion="entropy"`.

No imponer inicialmente restricciones de profundidad o tamaño de hojas. Para cada modelo reportar:

- exactitud en entrenamiento;
- exactitud en prueba;
- profundidad real mediante `get_depth()`;
- número de hojas mediante `get_n_leaves()`.

Visualizar al menos uno de los árboles y analizar las tres primeras reglas de decisión en términos del contexto.

5. Pre-poda: profundidad y tamaños mínimos

Realizar experimentos independientes, cambiando un parámetro a la vez.

Parámetro	**Valores mínimos que deben compararse**
`max_depth`	$2, 3, 4, 5,$ `None`
`min_samples_split`	$2, 5, 10, 20$
`min_samples_leaf`	$1, 2, 5, 10$

Para cada valor registrar exactitud de entrenamiento, exactitud de prueba, profundidad y número de hojas. Interpretar qué ocurre con la complejidad cuando la restricción se vuelve más fuerte.

6. Número máximo de hojas

En `scikit-learn`, el parámetro

`max_leaf_nodes`

limita el número máximo de nodos terminales. Si se denota ese límite por $L_{\text{máx}}$,

$$|\widetilde{T}| \leq L_{\text{máx}},$$

con $|\widetilde{T}|$ igual al número de hojas del árbol.

En un árbol binario completo con L hojas existen como máximo $L - 1$ nodos internos y, por tanto, $2L - 1$ nodos totales. Esto permite relacionar el número de regiones terminales con la complejidad estructural.

Comparar:

$$L_{\text{máx}} \in \{3, 5, 8, 12, \texttt{None}\}.$$

Responder: ¿reducir el número máximo de hojas produce el mismo efecto que reducir `max_depth`? Explicar usando la estructura de los árboles obtenidos.

7. Poda por complejidad de coste

Partir de un árbol sin poda y obtener la ruta

```
ruta = modelo_base.cost_complexity_pruning_path(
    X_train,
    y_train
)

alphas = ruta.ccp_alphas
```

Seleccionar al menos cuatro valores de `ccp_alpha` distintos, evitando limitar el análisis al último valor si este reduce el árbol únicamente a la raíz. Para cada α reportar:

- exactitud en entrenamiento y prueba;
- profundidad;
- número de hojas.

Relacionar el experimento con

$$R_\alpha(T) = R(T) + \alpha|\widetilde{T}|.$$

Explicar qué término favorece el ajuste y qué término penaliza la complejidad.

8. Modelo de árbol seleccionado por el grupo

Elegir un árbol razonable a partir de los experimentos anteriores. La justificación no puede limitarse a "obtuvo la mayor exactitud". Debe incluir:

- diferencia entre desempeño de entrenamiento y prueba;
- profundidad y número de hojas;
- interpretabilidad de las reglas;
- evidencia de sobreajuste o subajuste;
- parámetros de pre-poda o poda utilizados.

Parte II: formulación matemática de la SVM

9. Estandarización y codificación de las clases

Ajustar `StandardScaler` únicamente con X_{train}. Denotar cada observación estandarizada por

$$\mathbf{z}_i = (z_{i1}, \ldots, z_{ip})^T.$$

Para los cálculos de margen utilizar etiquetas

$$y_i^* = 2y_i - 1,$$

por lo que

$$y_i = 0 \Longrightarrow y_i^* = -1, \qquad y_i = 1 \Longrightarrow y_i^* = +1.$$

Explicar por qué el árbol se trabajó en las unidades originales mientras que la SVM requiere especial atención a la escala de las características.

10. SVM lineal y ecuación del hiperplano

Ajustar

```
SVC(kernel="linear", C=C)
```

para

$$C \in \{0{,}1, 1, 100\}.$$

Para cada valor reportar:

- exactitud de entrenamiento y prueba;
- número total de vectores de soporte;
- vector $\mathbf{w}$ mediante `coef_`;
- intercepto b mediante `intercept_`;
- norma $\|\mathbf{w}\|_2$;
- ancho total del margen

$$M = \frac{2}{\|\mathbf{w}\|_2}.$$

Para el valor de C que el grupo analice con mayor detalle, escribir explícitamente la ecuación

$$\boxed{\mathbf{w}^\top \mathbf{z} + b = 0}$$

y los dos bordes del margen

$$\boxed{\mathbf{w}^\top \mathbf{z} + b = 1, \qquad \mathbf{w}^\top \mathbf{z} + b = -1.}$$

Observación

Las ecuaciones anteriores deben escribirse con los coeficientes numéricos obtenidos por el grupo y corresponden al espacio de características estandarizadas $\mathbf{z}$.

4. Representación geométrica según la dimensión

- **Si $p = 2$:** construir un gráfico con las observaciones de entrenamiento, el hiperplano lineal, las dos fronteras del margen $f(\mathbf{z}) = \pm 1$ y los vectores de soporte. Además, visualizar las fronteras de decisión de los kernels lineal, polinomial y RBF.
- **Si $p = 3$:** representar en tres dimensiones el hiperplano del modelo lineal y las observaciones. Escribir también las ecuaciones numéricas de la frontera y de los dos márgenes. Para kernels no lineales no es obligatorio dibujar una superficie tridimensional completa; debe presentarse su ecuación de decisión en forma de kernel.
- **Si $p > 3$:** no se exige una representación geométrica del hiperplano. Debe presentarse la ecuación numérica

  $$w_1 z_1 + w_2 z_2 + \cdots + w_p z_p + b = 0$$

  y las ecuaciones correspondientes a $+1$ y -1.

No se aceptará una gráfica construida únicamente con dos variables cuando $p > 2$ como si esa gráfica representara la frontera completa del modelo. Una proyección bidimensional puede utilizarse como exploración, pero debe identificarse explícitamente como proyección.

Parte III: comparación árbol–SVM

Construir una tabla final que contenga, como mínimo:

Modelo	**Complejidad relevante**	**Exactitud train/test**	**Elemento interpretable**
Árbol sin poda	profundidad y hojas		reglas
Árbol seleccionado	profundidad, hojas, α		reglas
SVM lineal	C, margen, SV		hiperplano
SVM polinomial	C, d, SV		kernel
SVM RBF	C, γ, SV		kernel

Responder de manera argumentada:

1. ¿Qué evidencia muestra que el árbol sin restricciones sobreajusta o no sobreajusta?
2. ¿Qué parámetro de pre-poda tuvo mayor efecto sobre el tamaño del árbol en su dataset?
3. ¿Qué efecto produjo aumentar `ccp_alpha`?
4. ¿Qué relación observó entre C y el ancho del margen de la SVM lineal?
5. ¿Cómo cambió el número de vectores de soporte al modificar C?
6. ¿Existe evidencia de que una frontera lineal sea insuficiente para su problema? Sustentar con resultados y, cuando sea posible, con la geometría observada.
7. ¿Qué efecto produjo γ en el kernel RBF?
8. Comparar la forma de controlar complejidad en árboles y en SVM. No afirmar que los parámetros son equivalentes; explicar qué controla cada uno.
9. Seleccionar una de las alternativas estudiadas para el problema asignado y justificarla desde el ajuste, la complejidad y la interpretación contextual.

5. Entregables

Cada grupo debe entregar un archivo `.ipynb` ejecutable de principio a fin; que contenga:

1. todas las figuras generadas por el grupo dentro del notebook;
2. una tabla resumen de los experimentos realizados;
3. una conclusión técnica que compare el árbol y las SVM sin reducir la discusión a la exactitud.

El notebook debe conservar el orden de la actividad y separar claramente los cálculos manuales, los experimentos del árbol y los experimentos de SVM.